Optimización Numérica y Combinatoria: Análisis Comparativo de Métodos Deterministas y Heurísticos

Redes Neuronales y Algoritmos Bioinspirados - Optimización Numérica y optimización combinatoria

Docente

Juan David Ospina Arango

Integrantes

Jean Carlos Perilla Garcia

Emmanuel Alberto Mejia Arango

Juan Camilo Lopez Morales

Institución

Universidad Nacional de Colombia

Sede Medellín - Facultad de Minas

Fecha

24 de marzo de 2026

Parte 1: optimización numérica

Considere las siguientes funciones de prueba:

- Función de Rosenbrock
- Función de Rastrigin
- Función de Schwefel.
- Función de Griewank
- Función Goldstein-Price
- Función de las seis jorobas de camello

1. Escoja dos funciones de prueba

Función de Rosenbrock

La función de Rosenbrock, también conocida como la función del *valle banana*, es una de las funciones de prueba más utilizadas en optimización continua. Su forma general en n dimensiones es:

$$f(\mathbf{x}) = \sum_{i=1}^{n-1} \left[100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2\right]$$

Esta función presenta un único mínimo global ubicado en el punto x = (1,1,...,1), donde el valor de la función es cero.

Descripción y enfoque

La principal dificultad de la función de Rosenbrock radica en su topología: posee un valle estrecho, curvo y alargado que conduce al mínimo global. Aunque no contiene múltiples mínimos locales significativos, su geometría hace que los algoritmos de optimización basados en gradiente puedan experimentar:

- Convergencia lenta.
- Oscilaciones dentro del valle.
- Alta sensibilidad a la tasa de aprendizaje.

Justificación de selección

Se selecciona esta función porque permite evaluar la capacidad de los algoritmos para:

- Seguir trayectorias no lineales hacia el óptimo.
- Ajustar correctamente los pasos de actualización.
- Manejar problemas con mala condición numérica.

Es particularmente útil para analizar el comportamiento del descenso por gradiente.

Función de Rastrigin

La función de Rastrigin es una función altamente multimodal, comúnmente utilizada como benchmark en optimización global. Su forma general en n dimensiones es:

$$f(\mathbf{x}) = 10n + \sum_{i=1}^{n} \left[x_i^2 - 10\cos(2\pi x_i)\right]$$

El mínimo global se encuentra en x=(0,0,...,0), donde el valor de la función es cero.

A diferencia de Rosenbrock, la función de Rastrigin presenta una gran cantidad de mínimos locales distribuidos periódicamente en todo el espacio de búsqueda. Esto la convierte en un problema complejo para algoritmos de optimización, especialmente aquellos que dependen de información local.

Sus características principales incluyen:

- Alta multimodalidad.
- Superficie altamente ondulada.
- Gran probabilidad de convergencia prematura en óptimos locales.

Se selecciona esta función porque permite evaluar:

- La capacidad de exploración global de los algoritmos.
- La habilidad para escapar de mínimos locales.
- La robustez frente a paisajes de búsqueda complejos.

Es especialmente útil para analizar el desempeño de métodos heurísticos como algoritmos evolutivos, PSO y evolución diferencial.

2. Optimice las funciones en dos y tres dimensiones usando un método de descenso por gradiente con condición inicial aleatoria

2. Optimización en dos y tres dimensiones mediante descenso por gradiente con condición inicial aleatoria

2.1 Objetivo

En esta etapa se busca optimizar las funciones de Rosenbrock y Rastrigin en espacios de dos y tres dimensiones usando el método de descenso por gradiente, partiendo en cada ejecución desde una condición inicial aleatoria. El propósito es analizar el comportamiento de un método clásico de optimización numérica sobre

dos paisajes de búsqueda con características muy distintas: uno suave pero mal condicionado y otro altamente multimodal.

2.2 Fundamento del método

El descenso por gradiente es un método iterativo de optimización que actualiza la solución en dirección opuesta al gradiente de la función objetivo, ya que esa dirección corresponde al máximo descenso local. La regla de actualización está dada por:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \eta \nabla f(\mathbf{x}^{(k)})$$

donde:

$\mathbf{x}^{(k)}$ es la solución en la iteración k,
η es la tasa de aprendizaje,
$\nabla f(\mathbf{x}^{(k)})$ es el gradiente de la función evaluado en la iteración actual.

El método se repite hasta cumplir un criterio de parada, por ejemplo:

- alcanzar un número máximo de iteraciones,
- obtener una norma del gradiente suficientemente pequeña,
- o detectar cambios mínimos en el valor de la función entre iteraciones consecutivas.

2.3 Formulación de las funciones en 2D y 3D

2.3.1 Función de Rosenbrock

En dos dimensiones:

$$f(x, y) = 100(y - x^2)^2 + (1 - x)^2$$

En tres dimensiones:

$$f(x, y, z) = 100(y - x^2)^2 + (1 - x)^2 + 100(z - y^2)^2 + (1 - y)^2$$

Su mínimo global está en: **(1,1) y (1,1,1)** respectivamente, con valor óptimo igual a cero.

Gradiente de Rosenbrock en 2D:

$$\frac{\partial f}{\partial x} = -400x(y - x^2) - 2(1 - x)$$

$$\frac{\partial f}{\partial y} = 200(y - x^2)$$

Gradiente de Rosenbrock en 3D:

$$\frac{\partial f}{\partial x} = -400x(y - x^2) - 2(1 - x)$$

$$\frac{\partial f}{\partial y} = 200(y - x^2) - 400y(z - y^2) - 2(1 - y)$$

$$\frac{\partial f}{\partial z} = 200(z - y^2)$$

2.3.2 Función de Rastrigin

En n dimensiones:

$$f(\mathbf{x}) = 10n + \sum_{i=1}^{n} \left(x_i^2 - 10\cos(2\pi x_i)\right)$$

En dos dimensiones:

$$f(x, y) = 20 + x^2 - 10\cos(2\pi x) + y^2 - 10\cos(2\pi y)$$

En tres dimensiones:

$$f(x, y, z) = 30 + x^2 - 10\cos(2\pi x) + y^2 - 10\cos(2\pi y) + z^2 - 10\cos(2\pi z)$$

Su mínimo global está en: (0,0) y (0,0,0) con valor óptimo igual a cero.

Gradiente de Rastrigin

Para cada componente Xi:

$$\frac{\partial f}{\partial x_i} = 2x_i + 20\pi \sin(2\pi x_i)$$

Entonces, en 2D:

$$\nabla f(x, y) = (2x + 20\pi \sin(2\pi x), 2y + 20\pi \sin(2\pi y))$$

y en 3D:

$$\nabla f(x, y, z) = (2x + 20\pi \sin(2\pi x), 2y + 20\pi \sin(2\pi y), 2z + 20\pi \sin(2\pi z))$$

3. Optimice las funciones en dos y tres dimensiones usando: algoritmos evolutivos, optimización de partículas y evolución diferencial.

3. Optimización mediante métodos heurísticos

3.1 Objetivo

En esta sección se llevó a cabo la optimización de las funciones de Rosenbrock y Rastrigin en dos y tres dimensiones mediante el uso de métodos heurísticos de optimización global. En particular, se emplearon tres enfoques representativos:

- Algoritmo Genético (GA),
- Optimización por Enjambre de Partículas (PSO),
- Evolución Diferencial (DE).

El objetivo de esta etapa es evaluar el desempeño de estos métodos frente a problemas de optimización con características complejas, especialmente en escenarios donde los métodos deterministas, como el descenso por gradiente, presentan limitaciones debido a la presencia de múltiples óptimos locales o topologías no convexas.

3.2 Justificación del enfoque

Los métodos heurísticos se diferencian de los métodos deterministas en que incorporan mecanismos de exploración global del espacio de búsqueda. Mientras que los métodos deterministas dependen de información local (como el gradiente), los métodos heurísticos:

- operan sobre poblaciones de soluciones,
- incluyen componentes aleatorios o estocásticos,

- permiten explorar múltiples regiones simultáneamente,
- reducen la probabilidad de convergencia prematura en mínimos locales.

Estas características los hacen especialmente adecuados para funciones como Rastrigin, caracterizadas por alta multimodalidad, así como para funciones como Rosenbrock, cuya geometría dificulta la convergencia eficiente de métodos locales.

3.3 Algoritmo Genético (GA)

El algoritmo genético es un método de optimización inspirado en los principios de la evolución natural. En este enfoque, una población de soluciones evoluciona a lo largo de múltiples generaciones mediante la aplicación de operadores de selección, recombinación (cruce) y mutación.

Metodología aplicada

- Cada individuo fue representado como un vector de variables reales de dimensión 2 o 3.
- La población inicial se generó aleatoriamente dentro de los límites definidos para cada función.
- La función objetivo se utilizó como medida de aptitud (fitness).
- Se estableció un número máximo de generaciones para la evolución del algoritmo.
- Se implementó un mecanismo de conteo de evaluaciones de la función objetivo mediante funciones auxiliares (*wrappers*).

Comportamiento observado

El algoritmo genético mostró una adecuada capacidad de exploración del espacio de búsqueda, logrando aproximarse al mínimo global en ambas funciones. No obstante, presentó limitaciones en la convergencia fina, especialmente en regiones cercanas al óptimo, lo cual se refleja en valores finales ligeramente superiores al mínimo teórico.

3.4 Optimización por Enjambre de Partículas (PSO)

El algoritmo de optimización por enjambre de partículas (PSO) está inspirado en el comportamiento colectivo de sistemas naturales. Cada partícula representa una solución candidata y ajusta su posición en función de su experiencia individual y del conocimiento global del enjambre.

Metodología aplicada

- Se inicializó un conjunto de partículas distribuidas aleatoriamente en el espacio de búsqueda.

- En cada iteración, las partículas actualizaron su posición considerando:
    - su mejor posición histórica,
    - la mejor posición global encontrada por el enjambre.
- Se registró la trayectoria de la mejor solución para su posterior análisis.
- Se evaluó el desempeño del algoritmo en problemas de dos y tres dimensiones.

Comportamiento observado

El PSO presentó una convergencia rápida y consistente en ambas funciones. Mostró alta robustez frente a la inicialización aleatoria y una notable capacidad para evitar mínimos locales, particularmente en la función de Rastrigin. En general, el algoritmo logró alcanzar el mínimo global de manera estable.

3.5 Evolución Diferencial (DE)

Descripción

La evolución diferencial es un método poblacional de optimización continua que genera nuevas soluciones mediante la combinación de diferencias entre individuos existentes. Su estructura simple y eficiente lo hace especialmente adecuado para problemas de optimización no lineal.

Metodología aplicada

- Se definieron los límites del espacio de búsqueda como restricciones para cada variable.
- Se utilizó la estrategia estándar *best1bin*.
- Se configuraron parámetros como tamaño de población y número máximo de iteraciones.
- Se implementó un contador de evaluaciones de la función objetivo.

Comportamiento observado

La evolución diferencial presentó el mejor desempeño global entre los métodos evaluados. Logró encontrar el mínimo global de forma consistente en ambas funciones y mostró una convergencia eficiente en términos de número de evaluaciones. Su comportamiento fue robusto tanto en funciones suaves como en funciones altamente multimodales.

3.6 Comparación de resultados

A partir de los resultados obtenidos, se pueden establecer las siguientes observaciones:

- El algoritmo genético mostró una adecuada exploración del espacio, pero menor precisión en la convergencia final.
- El PSO logró un equilibrio adecuado entre exploración y explotación, con resultados consistentes.
- La evolución diferencial presentó el mejor desempeño global, destacándose en precisión y eficiencia computacional.

En términos generales, los métodos heurísticos superaron ampliamente al descenso por gradiente en la función de Rastrigin, mientras que en la función de Rosenbrock lograron una convergencia más eficiente y estable.

3.7 Conclusión del punto

Los resultados obtenidos evidencian que los métodos heurísticos constituyen herramientas efectivas para la optimización de funciones complejas. Mientras que los métodos deterministas, como el descenso por gradiente, presentan limitaciones en presencia de múltiples óptimos locales, los métodos heurísticos permiten una exploración más amplia del espacio de búsqueda.

Entre los métodos evaluados, la evolución diferencial destacó como la técnica más eficiente y confiable, seguida por el PSO, mientras que el algoritmo genético mostró un buen desempeño general, aunque con limitaciones en la precisión final.

En consecuencia, la elección del método de optimización debe considerar las características del problema, siendo los métodos heurísticos especialmente recomendados en escenarios con alta complejidad y multimodalidad.

4. Represente con un gif animado o un video el proceso de optimización de descenso por gradiente y el proceso usando el método heurístico.

4. Visualización del proceso de optimización

4.1 Objetivo

El objetivo de esta sección es representar de manera visual el comportamiento de los algoritmos de optimización implementados, mediante el uso de animaciones y representaciones gráficas. Estas visualizaciones permiten analizar de forma intuitiva la evolución de las soluciones a lo largo de las iteraciones y comparar el desempeño entre métodos deterministas y heurísticos.

Se consideraron dos enfoques principales:

- Descenso por gradiente.

- Métodos heurísticos, específicamente optimización por enjambre de partículas (PSO).

4.2 Visualización 2D del descenso por gradiente

Para el descenso por gradiente se generaron animaciones en dos dimensiones utilizando gráficos de contorno. En estas representaciones:

- Los ejes corresponden a las variables del problema.
- El mapa de colores representa los valores de la función objetivo.
- La trayectoria del algoritmo se muestra como una línea que conecta las posiciones sucesivas.
- Un punto indica la posición actual en cada iteración.

En la función de Rosenbrock, la visualización muestra que el algoritmo sigue una trayectoria curva a lo largo del valle característico de la función. Se observa una convergencia progresiva, aunque lenta, debido a la geometría estrecha del problema.

En la función de Rastrigin, el algoritmo se desplaza hacia regiones de menor valor de la función, pero tiende a quedar atrapado en mínimos locales. Esto evidencia la limitación del descenso por gradiente en funciones altamente multimodales.

Figuras

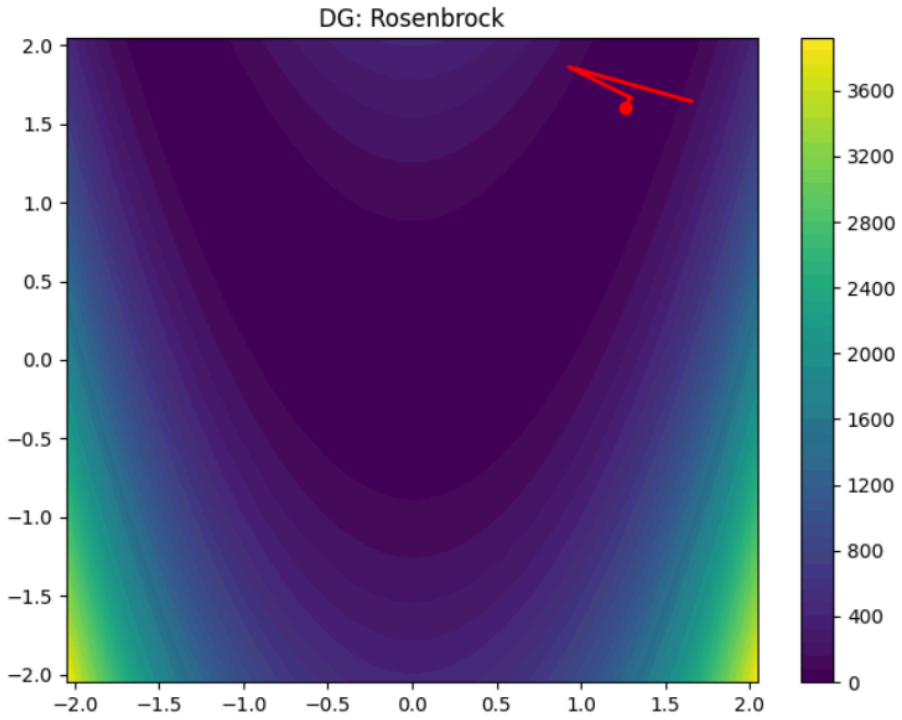

Figura 1. *Animación del descenso por gradiente en la función de Rosenbrock.*

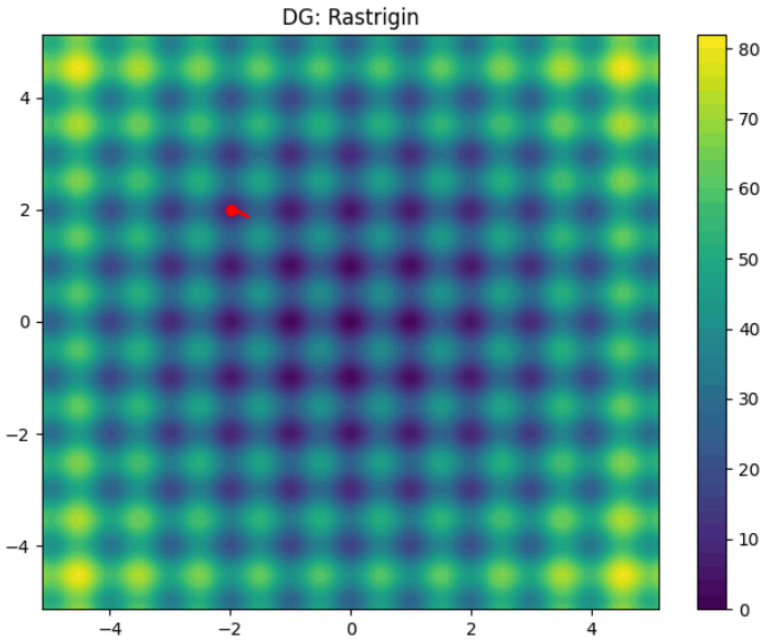

Figura 2. *Animación del descenso por gradiente en la función de Rastrigin.*

4.3 Visualización 2D del método heurístico (PSO)

Para los métodos heurísticos se utilizó la optimización por enjambre de partículas (PSO), debido a su naturaleza poblacional, que permite observar múltiples soluciones de manera simultánea.

En las animaciones:

- Cada partícula representa una solución candidata.
- Las partículas se desplazan en el espacio de búsqueda a lo largo de las iteraciones.
- Se observa la convergencia colectiva hacia el mínimo global.

En la función de Rosenbrock, las partículas convergen gradualmente hacia el valle donde se encuentra el mínimo global. Se observa un comportamiento cooperativo entre las partículas, lo que facilita la convergencia.

En la función de Rastrigin, el enjambre explora diversas regiones del espacio de búsqueda antes de converger. A diferencia del descenso por gradiente, el PSO evita quedar atrapado en mínimos locales y logra aproximarse al mínimo global de manera consistente.

Figuras

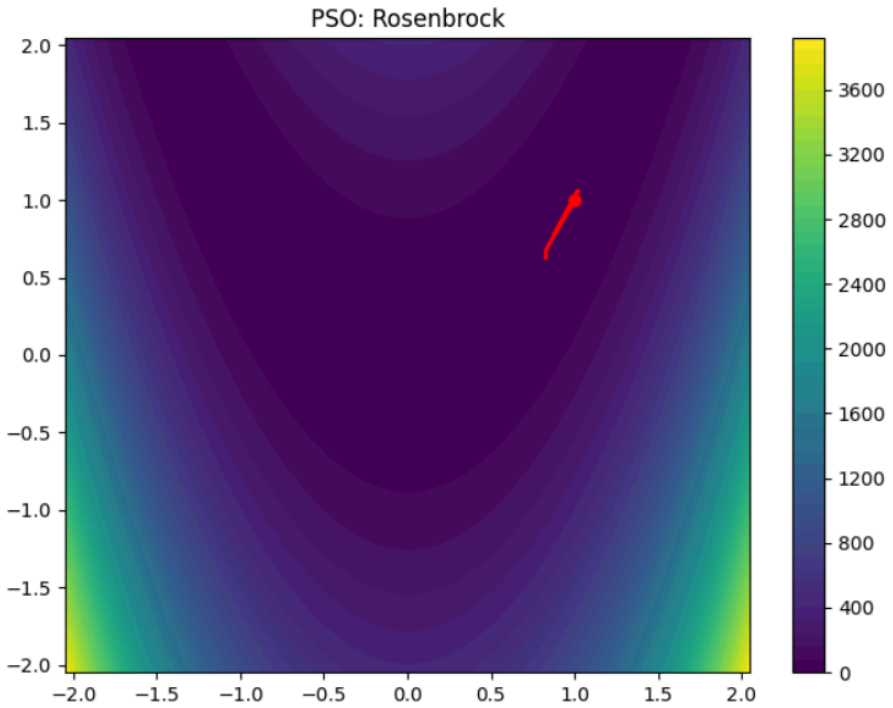

Figura 3. *Animación del algoritmo PSO en la función de Rosenbrock*.

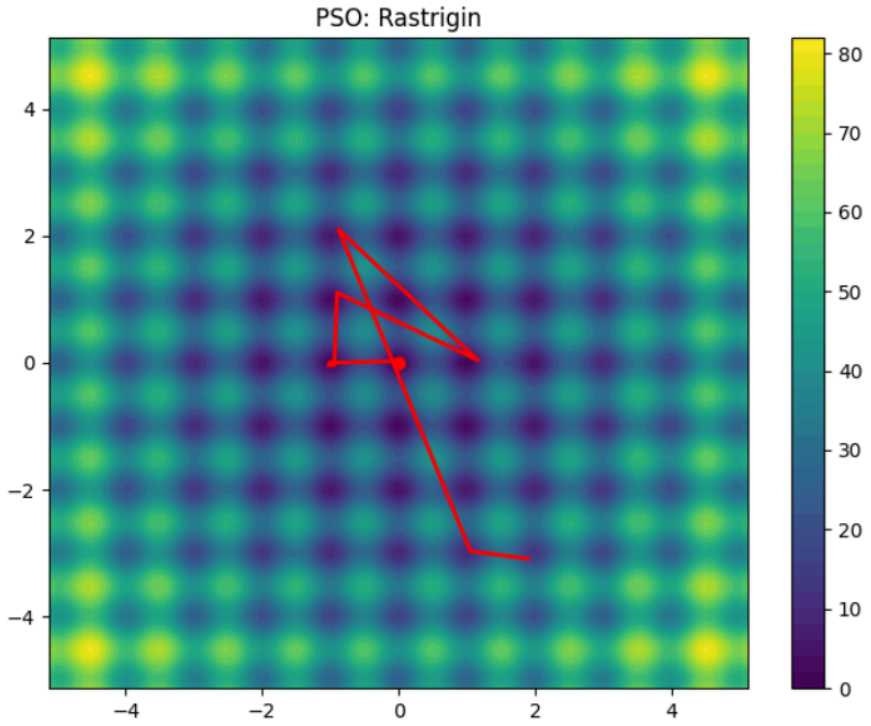

Figura 4. *Animación del algoritmo PSO en la función de Rastrigin.*

4.4 Visualización en 3D

Adicionalmente, se generaron representaciones tridimensionales de las funciones, en las cuales:

- La superficie representa la función objetivo.
- La trayectoria del algoritmo se proyecta sobre dicha superficie.

Estas visualizaciones permiten comprender la topología del problema y analizar la dinámica del algoritmo en el espacio de búsqueda.

Figuras

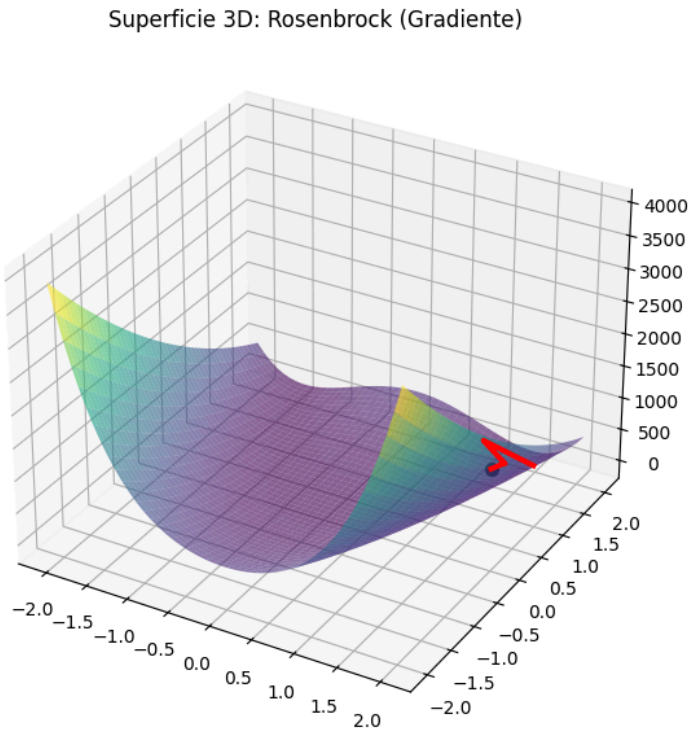

Figura 5. *Superficie tridimensional de la función de Rosenbrock con la trayectoria del descenso por gradiente.*

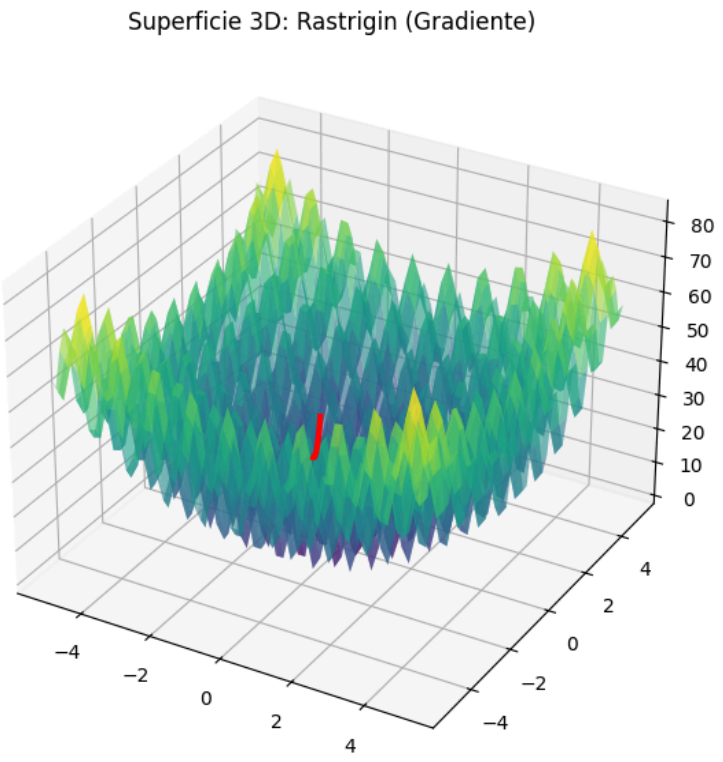

Figura 6. *Superficie tridimensional de la función de Rastrigin con la trayectoria del descenso por gradiente.*

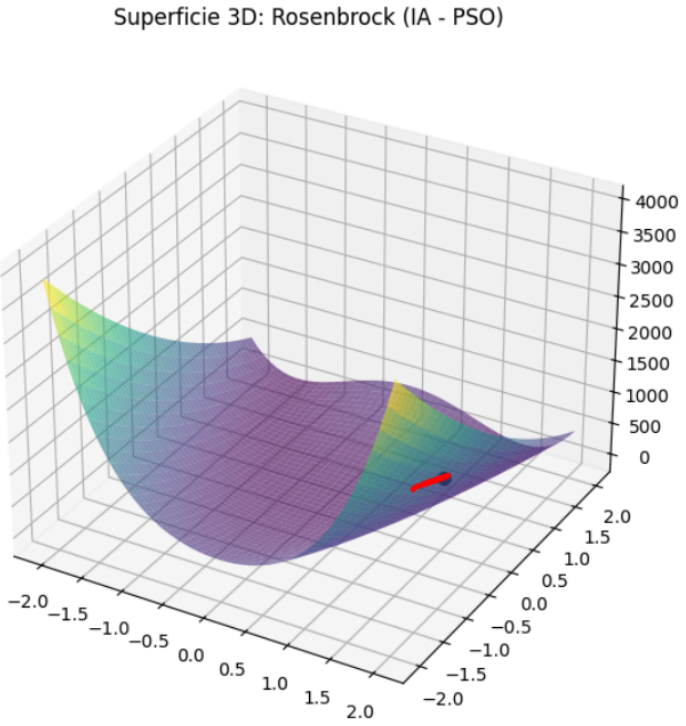

Figura 7. *Superficie tridimensional de la función de Rosenbrock con la trayectoria del algoritmo PSO.*

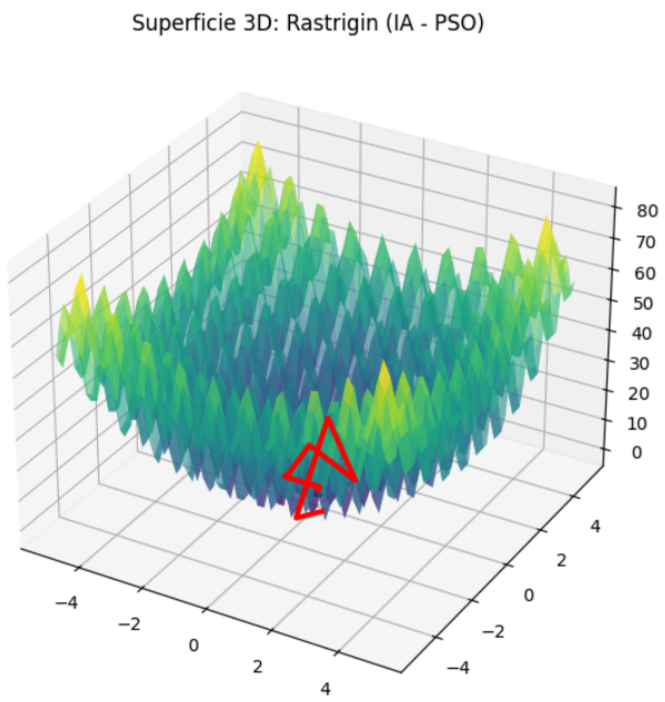

Figura 8. *Superficie tridimensional de la función de Rastrigin con la trayectoria del algoritmo PSO*.

4.5 Análisis comparativo

A partir de las visualizaciones, se identifican diferencias claras entre los métodos:

- El descenso por gradiente sigue una única trayectoria determinada por el gradiente local.
- Los métodos heurísticos exploran múltiples regiones del espacio simultáneamente.
- El descenso por gradiente presenta dificultades para escapar de mínimos locales.
- El PSO muestra una mayor capacidad de exploración global y convergencia hacia el mínimo global.

4.6 Conclusión del punto

La representación visual de los algoritmos permitió comprender de manera clara sus diferencias en términos de comportamiento y desempeño.

El descenso por gradiente demostró ser un método eficiente en problemas suaves, pero limitado por su carácter local. Por otro lado, los métodos heurísticos, al incorporar mecanismos de exploración global, lograron un mejor desempeño en funciones complejas como Rastrigin.

Las animaciones y representaciones gráficas no solo facilitaron la interpretación de los resultados, sino que también permitieron validar experimentalmente el comportamiento teórico de los algoritmos analizados.

Discuta

¿Qué aportaron los métodos de descenso por gradiente y qué aportaron los métodos heurísticos? Para responder a esta pregunta considere el valor final de la función objetivo y el número de evaluaciones de la función objetivo. Para responder a esta pregunta es posible que se requiera hacer varias corridas de los algoritmos.

Método	Valor final de la función objetivo	Evaluaciones de la función	Aporte principal
Descenso por gradiente	Cercano al óptimo en Rosenbrock (~0.99); alto en Rastrigin (~18–20)	Bajo en Rastrigin (~30); alto en Rosenbrock (~1000)	Alta eficiencia local, pero fuerte dependencia del punto inicial y limitada capacidad para evitar mínimos locales
Algoritmo Genético (GA)	Cercano al óptimo (≈0.07 en Rosenbrock; ≈0.69 en Rastrigin)	Alto (~10000)	Buena exploración global, pero limitada precisión en la convergencia final
PSO	Óptimo global (≈0.0) en ambas funciones	Medio-alto (~6000)	Alta robustez y convergencia estable hacia el óptimo global
Evolución Diferencial (DE)	Óptimo global (≈0.0) en ambas funciones	Medio (~2000–4000)	Mejor balance entre exploración y explotación; alta eficiencia y precisión

Tabla 1. *Comparación del desempeño de los métodos de DG y PSO.*

A partir de los resultados presentados en la Tabla 1, se observa que el descenso por gradiente presenta un comportamiento eficiente en términos de número de evaluaciones en algunos casos, pero con una calidad de solución limitada, especialmente en la función de Rastrigin donde converge rápidamente a mínimos locales con valores alejados del óptimo, mientras que en Rosenbrock requiere un alto número de evaluaciones sin lograr una convergencia precisa; en contraste, los métodos heurísticos alcanzan de manera consistente valores cercanos o iguales al óptimo global, aunque con un mayor costo computacional, destacándose la

evolución diferencial por lograr el mejor balance entre precisión y número de evaluaciones, seguida por PSO con alta estabilidad y el algoritmo genético con buena exploración pero menor precisión final, lo que evidencia un compromiso claro entre eficiencia computacional y calidad de la solución.

Parte 2: optimización combinatoria

Optimización combinatoria del recorrido por las 32 capitales de México usando Algoritmo Genético y Colonia de Hormigas

1. Resumen

Se modeló un problema de vendedor viajero (TSP) para recorrer las 32 capitales estatales de México, minimizando un costo total de desplazamiento compuesto por combustible, peajes y costo del tiempo del vendedor. Se implementaron dos metaheurísticas: Algoritmo Genético (GA) y Optimización por Colonia de Hormigas (ACO). Se evaluó la sensibilidad del modelo frente al valor hora del vendedor. Además, se generó una visualización del recorrido final en un mapa (GIF). Los resultados muestran que ambos métodos logran rutas competitivas, con diferencias en convergencia y costo final según la parametrización.

3. Introducción

El problema del vendedor viajero (TSP) es una referencia clásica en optimización combinatoria y logística. Su complejidad combinatoria crece rápidamente con el número de ciudades, por lo que para instancias medianas/grandes es común emplear metaheurísticas en lugar de métodos exactos.
En este estudio, se formula un TSP aplicado a México con 32 capitales, usando una función de costo más realista que incorpora combustible, peajes y tiempo de desplazamiento.

4. Metodología

4.1 Datos y representación espacial

Se construyó un conjunto de 32 nodos correspondientes a capitales estatales de México, con coordenadas geográficas (latitud, longitud).
La distancia entre ciudades se aproximó con la fórmula de Haversine (km sobre esfera terrestre), adecuada cuando no se cuenta con una API de rutas carreteras.

4.2 Función objetivo

Para cada tramo $i \ -> \ j$ se define el costo como: $C_{ij} = C_{ij}^{comb} + C_{ij}^{peaje} + C_{ij}^{tiempo}$

costo de combustible: $C_{ij}^{comb} = d_{ij} * P_{gas}/R$

Costo de peaje : $C_{ij}^{peaje} = d_{ij} * fpeaje$

costo por tiempo: $C_{ij}^{tiempo} = d_{ij} * V_h/v$

-Definición de variables:

d_{ij} : distancia entre i y j (calculada con Haversine, en km)

P_{gas} : precio del combustible por litro

R : rendimiento del vehículo (km/l)

f_{peaje} : costo de peaje aproximado por km

V_h : valor por hora del vendedor

v: velocidad promedio (km/h)

Costo total de la ruta:

El costo total de una ruta se calcula como la suma de los costos de todos los tramos:

$$C_{total} = \mathbf{\Sigma} C_{ij}$$

El costo total de una ruta es la suma de costos de todos los tramos, incluyendo retorno al origen.

4.3 Algoritmos implementados

- GA (Genetic Algorithm): población de permutaciones, selección por torneo, cruce OX y mutación swap con elitismo.
- ACO (Ant Colony Optimization): construcción probabilística de rutas guiada por feromona y heurística ((1/costo)), evaporación y depósito de feromonas por calidad de ruta.

4.4 Escenarios evaluados

Se evaluaron distintos valores del parámetro (V_h) (por ejemplo 100, 200, 300 MXN/h), manteniendo fijos los demás parámetros del vehículo y costos.

5. Resultados

5.1 Tabla de desempeño

metodo	valor_hora	costo_total_mxn	distancia_total_km	costo_prom_km_mxn
ACO	100	32357.262238	9175.537248	3.526471
GA	100	34693.477489	9838.016969	3.526471
ACO	200	41532.708109	8831.219986	4.702941
GA	200	50601.866321	10759.621357	4.702941
ACO	300	53169.455607	9043.329118	5.879412
GA	300	55387.100185	9420.517290	5.879412

Tabla 2. *Resultados comparativos GA vs ACO para cada valor de hora.*

En la Tabla 2 se observa el costo total y la distancia total de la mejor ruta obtenida por cada algoritmo. El incremento de (V_h) desplaza el costo total hacia valores mayores, manteniendo tendencias similares en distancia.

5.2 Convergencia

Figura 9. Evolución del mejor costo acumulado por iteración (algoritmo ganador).

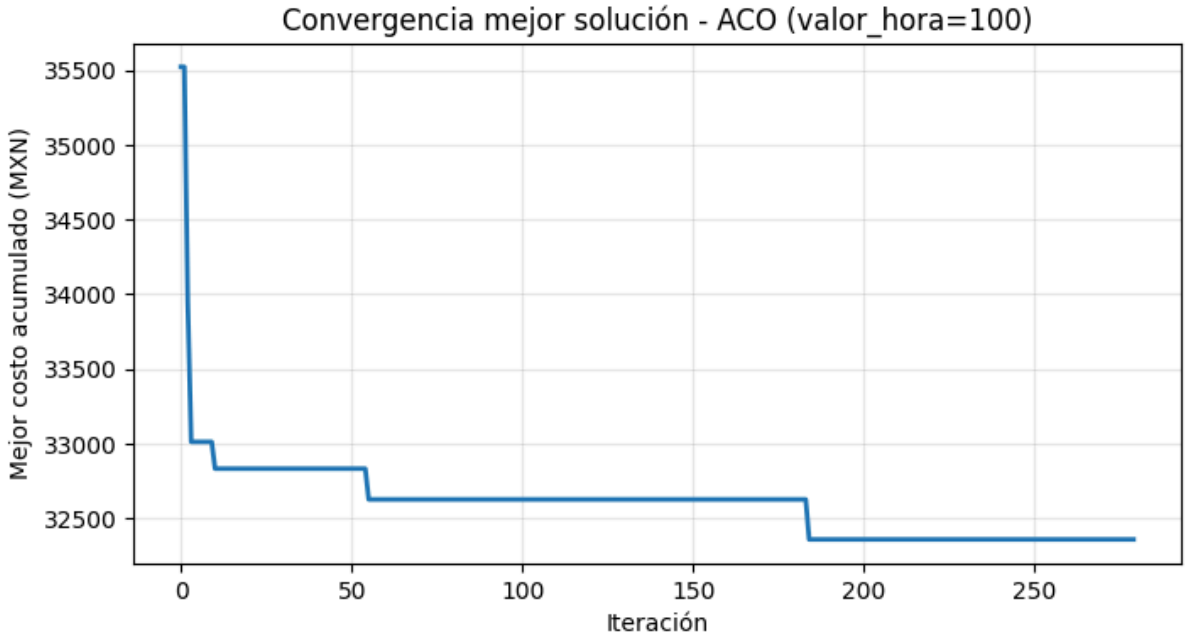

Figura 9. *Evolución del mejor costo acumulado por iteración (algoritmo ganador).*

La Figura 9 muestra una reducción acelerada del costo en iteraciones iniciales y una estabilización posterior, lo cual sugiere convergencia a una solución de alta calidad.

5.3 Visualización geográfica

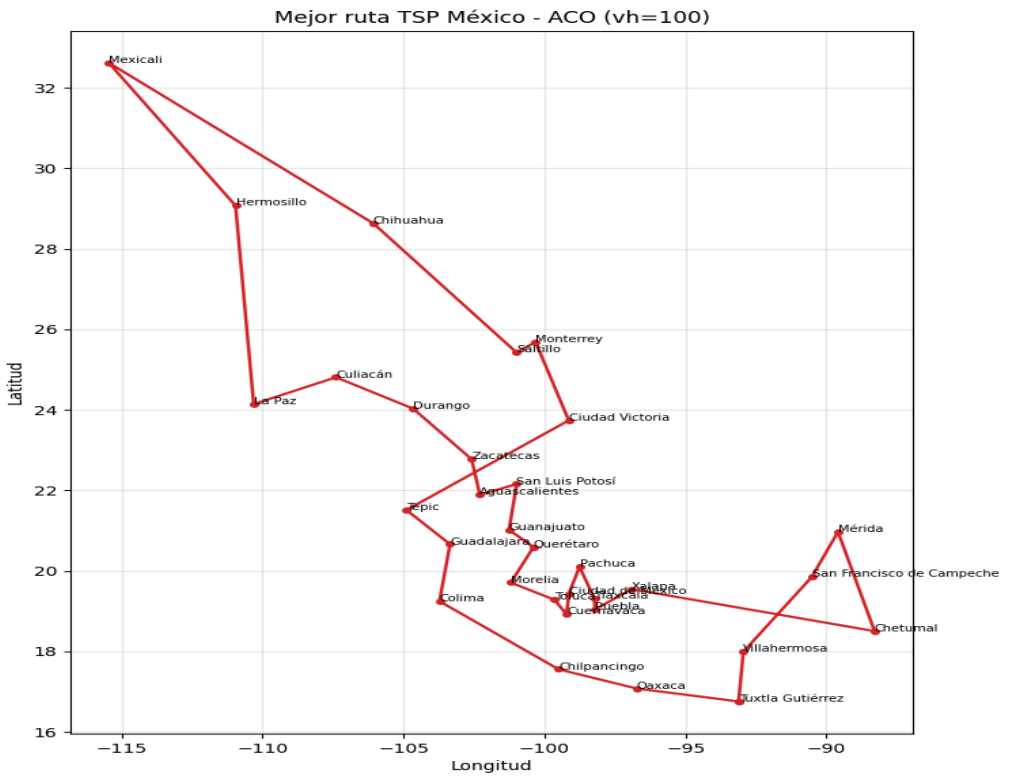

Figura 10. *Ruta final sobre coordenadas geográficas de México.*

La Figura 10 y el gif que genera el código permite interpretar espacialmente la secuencia de visita y validar visualmente la cobertura de las 32 capitales con retorno al punto inicial.

6. Discusión

- GA y ACO son apropiados para TSP por su capacidad de búsqueda global en espacios combinatorios grandes.
- El uso de Haversine simplifica el modelado cuando no hay red vial detallada; sin embargo, introduce diferencias frente a distancias reales por carretera.
- El parámetro (V_h) impacta directamente el costo total, por lo que su análisis es relevante para decisiones operativas.
- Para trabajo futuro, se recomienda integrar distancias y peajes reales por carretera (API o datasets viales).

7. Conclusiones

1. Se resolvió un TSP de 32 capitales con dos metaheurísticas exigidas por la consigna: GA y ACO.
2. La función de costo multimodal (combustible + peaje + tiempo) permitió una formulación más realista que minimizar solo distancia.

3. El análisis de sensibilidad del valor hora mostró su efecto en el costo total de operación.
4. La visualización animada facilitó la interpretación del comportamiento de la solución y su recorrido geográfico.

8. Uso de IA (obligatorio)

Prompts principales utilizados

1. “Explícame cómo modelar un TSP con costo compuesto por combustible, peajes y tiempo.”
2. “Genera código en Python para GA y ACO aplicado a 32 ciudades con matriz de costo.”
3. “Ayúdame a crear un GIF animado de la mejor ruta sobre un mapa de coordenadas.”
4. “Redacta estructura de reporte técnico con metodología, discusión y bibliografía APA.”

Impacto de la IA en el resultado

La IA apoyó en: estructuración del código, depuración, diseño experimental y redacción técnica.
El equipo validó y ajustó manualmente parámetros, interpretación de resultados y narrativa final.
Por tanto, la IA funcionó como asistente de productividad, pero las decisiones metodológicas y de análisis fueron responsabilidad del equipo.

9. Bibliografía en APA (base sólida)

Bibliografía

- Rosenbrock, H. H. (1960). *An automatic method for finding the greatest or least value of a function*. The Computer Journal.
- Rastrigin, L. A. (1974). *Systems of extremal control*. Moscow: Nauka.
- Nocedal, J., & Wright, S. (2006). *Numerical Optimization*. Springer.
- Kennedy, J., & Eberhart, R. (1995). *Particle Swarm Optimization*. IEEE.
- Storn, R., & Price, K. (1997). *Differential Evolution – A Simple and Efficient Heuristic for Global Optimization*. Journal of Global Optimization.
- Dorigo, M., & Stützle, T. (2004). Ant Colony Optimization. MIT Press.
- Holland, J. H. (1992). Adaptation in Natural and Artificial Systems. MIT Press. (Original work published 1975)
- Lawler, E. L., Lenstra, J. K., Rinnooy Kan, A. H. G., & Shmoys, D. B. (Eds.). (1985). The Traveling Salesman Problem: A Guided Tour of Combinatorial Optimization. Wiley.
- Reinelt, G. (1994). The Traveling Salesman: Computational Solutions for TSP Applications. Springer.
- Goldberg, D. E. (1989). Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley.
- Stützle, T., & Hoos, H. H. (2000). MAX–MIN ant system. Future Generation Computer Systems, 16(8), 889–914.
- Sinnott, R. W. (1984). Virtues of the Haversine. Sky and Telescope, 68(2), 159.